

Documentazione: Exploratory Data Analysis & Data Cleaning

1. Ispezione Strutturale e Integrità dei Dati (Sanity Checks) L'analisi preliminare del dataset (8.986 record) ha confermato un'eccellente solidità strutturale. I controlli di integrità hanno escluso la presenza di righe duplicate e di conflitti temporali (assenza di registrazioni multiple per lo stesso utente nella medesima data). L'esplorazione della continuità temporale ha individuato una discontinuità fisiologica esclusivamente per gli utenti 6 e 22, caratterizzati da un gap di tracking di circa 7 giorni. Non sono stati rilevati valori logici impossibili nelle metriche di stile di vita (es. ore di sonno negative o superiori a 24 ore, assunzione di acqua irrealistica).

2. Strategia di Data Cleaning e Gestione dei Missing Values (NAs) La presenza di valori mancanti è stata gestita con due logiche distinte, rispettando la natura tecnica e clinica del dato:

- **Rimozione Mirata (Variabili di Ciclo):** I 38 NA presenti nelle colonne relative al ritmo biologico (`cycle_length_days`, `cycle_index`, `day_in_cycle`) sono imputabili esclusivamente alla sopracitata discontinuità temporale degli utenti 6 e 22. Per evitare di alterare il calcolo fisiologico del ciclo con interpolazioni fittizie, si è optato per la rimozione diretta (drop) di tali record.
- **Imputazione Soggettiva (Sintomatologia):** I 150 NA riscontrati nelle metriche sintomatologiche (`pain_level`, `mood_score`, `fatigue_score`) sono stati imputati utilizzando la **mediana calcolata per singolo utente**. Questa scelta metodologica preserva la baseline soggettiva di tolleranza al dolore o allo stress della singola paziente, azzerando il rischio di inquinamento statistico derivante dall'utilizzo di medie globali.

3. Esplorazione Visiva e Comportamentale (Visual Analytics) La visualizzazione dei dati ha permesso di estrarre pattern fondamentali che descrivono il comportamento della popolazione monitorata:

- **Trend Sintomatologico Intra-Ciclo:** L'aggregazione basata sul "tempo biologico" (`day_in_cycle`) ha evidenziato in modo netto l'andamento dei sintomi. Si osserva un picco fisiologico di `pain_level` e `fatigue_score` durante la finestra mestruale (giorni 1-5), seguito da una normalizzazione. Questo andamento non lineare è un segnale forte che i modelli predittivi dovranno catturare.
- **Impatto del Contraccettivo sulla Durata del Ciclo:** Il confronto grafico della distribuzione della durata del ciclo tra utenti con ciclo naturale e utenti con pillola contraccettiva ha mostrato differenze strutturali. Mentre il gruppo naturale presenta una fisiologica varianza (curva più larga), il gruppo con contraccettivo mostra una distribuzione leptocurtica (picco molto stretto) centrato sui classici 28 giorni indotti dal farmaco.
- **Fattori Demografici (Stress e Dolore per Fascia d'Età):** L'analisi bivariata ha fatto emergere differenze nella percezione e nell'occorrenza dei sintomi a seconda dell'età. I livelli medi di dolore e i punteggi di stress mostrano distribuzioni differenti a seconda del gruppo anagrafico analizzato, confermando l'`age` come variabile rilevante.

- **Fasi Biologiche (Stress Pre-Mestruale vs Post-Mestruale):** Segmentando i cicli nelle macro-fasi biologiche, è emersa una distinzione nei livelli di stress e umore tra la fase luteinica (pre-mestruale, tipicamente caratterizzata da instabilità ormonale e PMS) e la fase post-mestruale (follicolare).

4. Analisi delle Correlazioni e Implicazioni per il Machine Learning La matrice di correlazione *cross-sectional* applicata a tutte le feature (stile di vita, sintomi, parametri di ciclo, uso della pillola) non ha evidenziato relazioni lineari di forte impatto. L'uso della pillola, pur riducendo la varianza della durata del ciclo, non mostra una correlazione lineare dominante tale da richiedere la scissione del dataset. L'assenza di correlazioni "piatte" e lineari indica che le dinamiche che legano stile di vita e sintomatologia sono complesse e sfalsate nel tempo (lag effect). Di conseguenza, per le fasi di Predictive Analytics (Option C o Option D), i tradizionali modelli di regressione lineare risulteranno inefficaci. L'approccio modellistico dovrà orientarsi verso algoritmi basati su alberi decisionali (es. Random Forest) in grado di gestire interazioni non lineari e catturare l'importanza di variabili cicliche.